

医療サポートAIポータル（診療支援AI）システム構成図

Ubuntu 22.04 LTS / Node.js 構成スタック

環境: Production (PM2 Managed)

Web Client (Browser)

テキストPDF要約 UI

- index.ejs
- SSE (ReadableStream) 受信
- リアルタイム進捗バー表示

画像PDF (OCR) 要約 UI

- ocr-summary.ejs
- SSE (ReadableStream) 受信
- リアルタイム進捗バー表示

AIチャット UI

- 対話型インターフェース

Application Server (Node.js v20 / PM2)

HTTP / SSE Endpoint

routes/api.js

- POST /summarize-pdf
- POST /summarize-image-pdf
- POST /chat

※ text/event-stream によるリアルタイム進捗ストリーミング

Business Logic

services/

- summaryService.js
- ocrSummaryService.js
- chatService.js

★ Map-Reduce チャンク分割&2段階統合要約処理

通信タイムアウト制御: axios (timeout: 0) による無限待機仕様（長文推論でのタイムアウト防止）

Local Processing & AI Engine

Ollama Engine (Local LLM)

- API: http://127.0.0.1:11434
- コンテキスト長: num_ctx: 16384
- モデル: qwen2.5 / medgemma 等

Tesseract.js Engine

- 日本語OCR (jpn)
- pdf-to-img による画像変換
- 抽出テキストのログ出力

pdf-parse

- テキスト型PDFの高速文字列抽出

処理フローの特徴: 1. クライアントからPDFを送信 → 2. pdf-parse または Tesseract.js でテキスト抽出 → 3. 4,000文字単位にチャンク分割 (Mapフェーズ) → 4. axios で Ollama へ非同期リクエスト送信 (各進捗を SSE でフロントへ通知) → 5. 各部分要約を結合し最終サマリー作成 (Reduceフェーズ) → 6. 完成テキストをUIに描画